### Exercise CART Class 08-01-2020

Daniel Ferreira Zanchetta and Lais Silva Almeida Zanchetta

1. Suponga el siguiente árbol simple T con sólo dos nodos (hojas) terminales. En el nodo raíz se tiene 100 individuos que se dividen en dos nodos hijos de 60 y 40 individuos cada uno. La variable de respuesta indica la compra (No o Si) de un cierto producto. Calcule la reducción de impureza que se obtiene al pasar del nodo padre a los dos nodos hijos.

```
#Nodo 1:
pnodo1 <- (1/60)^2 + (59/60)^2

#Nodo 2:
pnodo2 <- (21/40)^2 + (19/40)^2

#Gini index padre
it0 <- round((pnodo1*(60/100) + pnodo2*(40/100)),3)

#Gini index nodo hijo 1
it1 <- round(1-(1/60)^2-(59/60)^2,3)

#Gini index nodo hijo 2
it2 <- round(1-(21/40)^2-(19/40)^2,3)

#Drecrement of impurity
deltait <- it0 - ((60/100)*it1) - ((40/100)*it2)
deltait
## [1] 0.5616
```

2. Con el mismo árbol precedente, calcule su coste de mal clasificación R(T).

```
#Para hacer el calculo del coste de cada nodo hijo (rt1 y rt2 abajo),
hemos utilizado el valor correspondiente al SI para realización de la
compra.
rt1 <- 1-(1/60)
rt1

## [1] 0.9833333
rt2 <- 1-(19/40)
rt2</pre>
```

3. Retome los datos del problema churn. Se trata ahora de obtener un árbol de decisión que nos permita efectuar predicciones sobre la probabilidad de baja de los clientes. Cargue en R la Liberia rpart y obtenga un árbol máximo (cp=0.0001) con crossvalidación (xval=10).

```
#library(mice)
library(rpart)
library(dplyr)
##
## Attaching package: 'dplyr'
## The following objects are masked from 'package:stats':
##
##
       filter, lag
## The following objects are masked from 'package:base':
##
##
       intersect, setdiff, setequal, union
library(tidyr)
library(mice)
## Warning: package 'mice' was built under R version 3.6.2
## Loading required package: lattice
##
## Attaching package: 'mice'
## The following object is masked from 'package:tidyr':
##
##
       complete
## The following objects are masked from 'package:base':
##
##
       cbind, rbind
setwd("C:/Users/Daniel/Documents/Certificados & Faculdade/UPC Master Big
Data/Data Analytics/Aula 8 - 08-01/exer_cart")
churn <- read.table(file = "churn.txt",header = TRUE,sep = "")</pre>
churn$antig[churn$antig==99] <- NA</pre>
churn <- mice::complete(mice(churn, m=1))</pre>
##
    iter imp variable
##
         1 antig Nomina Pension Debito aff VISA MCard
##
##
     2
         1 antig Nomina Pension Debito aff VISA MCard
```

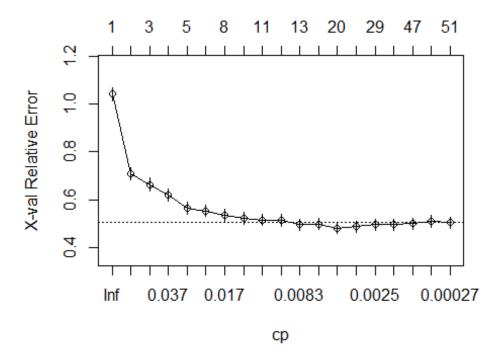
```
##
         1 antig Nomina Pension Debito_aff VISA MCard
         1 antig Nomina Pension Debito_aff VISA MCard
##
         1 antig Nomina Pension Debito aff VISA MCard
##
     5
churn tidy <- churn %>%
  separate(Baja, into = c("Baja Rem", "Baja"), sep = " ", extra = "merge",
fill = "left") %>%
  separate(edatcat, into = c("edatcat_Rem",
"edatcat","edatcat Rem2","edatcat Rem3"), sep = "([\\ \\.\])", extra =
"merge", fill = "right") %>%
  separate(Nomina, into = c("Nomina_Rem", "Nomina"), sep = " ", extra =
"merge", fill = "left") %>%
  separate(Pension, into = c("Pension_Rem", "Pension"), sep = " ", extra
= "merge", fill = "left") %>%
  separate(Debito normal, into =
c("Debito_normal_Rem","Debito_normal_Rem2", "Debito_normal"), sep = "([\\
\\ ])", extra = "merge", fill = "left") %>%
  separate(Debito_aff, into = c("Debito_aff_Rem", "Debito_aff_Rem2",
"Debito_aff"), sep = "([\\ \\. ])", extra = "merge", fill = "left") %>%
  separate(VISA, into = c("VISA Rem", "VISA"), sep = " ", extra =
"merge", fill = "left") %>%
  separate(VISA aff, into = c("VISA aff Rem","VISA aff Rem2",
"VISA_aff"), sep = "([\\ \\. ])", extra = "merge", fill = "left") %>%
  separate(MCard, into = c("MCard_Rem", "MCard"), sep = " ", extra =
"merge", fill = "left") %>%
  separate(Amex, into = c("Amex Rem", "Amex"), sep = " ", extra =
"merge", fill = "left") %>%
  separate(dif_resid, into = c("dif_resid_Rem","dif_resid_Rem2",
"dif_resid"),    sep = "([\\ \\. ])",    extra = "merge",    fill = "left") %>%
  transform(sexo = ifelse(.$sexo == "No informado", "MUJER", "HOMBRE"))
%>%
  select(-c("Baja Rem",
"edatcat_Rem", "edatcat_Rem2", "edatcat_Rem3", "Nomina_Rem", "Pension_Rem", "D
ebito normal Rem", "Debito normal Rem2", "Debito aff Rem", "Debito aff Rem2"
,"VISA_Rem","VISA_aff_Rem","VISA_aff_Rem2","MCard_Rem","Amex_Rem","dif_re
sid_Rem","dif_resid_Rem2"))
#Comandos para La generación de training data, con 2/3 (67% aprox) de
observaciones random
n <- nrow(churn tidy)</pre>
set.seed(7)
trainingdata <- sample(1:n,round(0.67*n))</pre>
#Comandos para la generación del arbol CART
set.seed(27)
arbbaja <- rpart(Baja~.,data = churn_tidy[trainingdata,],control =</pre>
rpart.control(cp=0.0001,xval = 10))
printcp(arbbaja)
```

```
##
## Classification tree:
## rpart(formula = Baja ~ ., data = churn_tidy[trainingdata, ],
       control = rpart.control(cp = 1e-04, xval = 10))
##
##
## Variables actually used in tree construction:
                                           dif CC
##
   [1] antig
                         Debito aff
                                                            dif Hipoteca
   [5] dif_Libreta
                                          dif_Seguros
##
                         dif_Plazo
                                                            edatcat
   [9] oper_caj_Libreta oper_ven_Libreta sexo
                                                            Total activo
## [13] Total Inversion Total Plazo
                                          Total Seguros
                                                            Total Vista
## [17] VISA
##
## Root node error: 663/1340 = 0.49478
##
## n= 1340
##
##
              CP nsplit rel error xerror
                                               xstd
## 1
      0.31070890
                      0
                          1.00000 1.04223 0.027593
## 2
                      1
      0.11010558
                          0.68929 0.70890 0.026348
                      2
                          0.57919 0.66365 0.025929
## 3
      0.04374057
## 4 0.03167421
                          0.53544 0.61840 0.025443
## 5
      0.01960784
                      4
                          0.50377 0.56410 0.024766
                          0.48416 0.55354 0.024622
## 6
      0.01809955
## 7
                      7
      0.01659125
                          0.44796 0.53394 0.024343
                      8
## 8
      0.01282051
                          0.43137 0.52187 0.024164
      0.01055807
## 9
                     10
                          0.40573 0.51584 0.024072
## 10 0.00904977
                     11
                          0.39517 0.51433 0.024049
## 11 0.00754148
                     12
                          0.38612 0.49623 0.023763
## 12 0.00452489
                     14
                          0.37104 0.49774 0.023788
                     19
## 13 0.00377074
                          0.34691 0.48115 0.023515
                     23
## 14 0.00251383
                          0.32881 0.48718 0.023615
## 15 0.00245098
                     28
                          0.31373 0.49623 0.023763
## 16 0.00226244
                     38
                          0.28808 0.49623 0.023763
## 17 0.00150830
                     46
                          0.26244 0.49925 0.023812
## 18 0.00075415
                     48
                          0.25943 0.50980 0.023979
## 19 0.00010000
                     50
                          0.25792 0.50377 0.023884
```

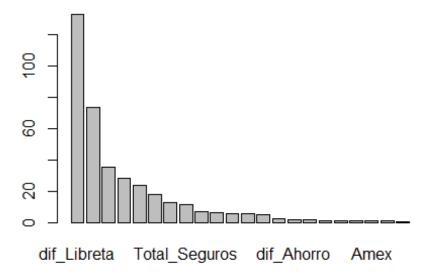
4. Determine ahora el árbol óptimo y su valor del complexity parameter (cp). Diga cuales son las variables más importantes en la definición del árbol óptimo.

```
plotcp(arbbaja)
```

#### size of tree



```
arbbaja$cptable <- as.data.frame(arbbaja$cptable)</pre>
#Descubrir el index del arbol con menos calidad
indMenorXError <- which.min(arbbaja$cptable$xerror)</pre>
#Grabar el registro en una nueva variable
xerror <- arbbaja$cptable$xerror[indMenorXError]</pre>
#Coger su respectiva standard variation
sd <- arbbaja$cptable$xstd[indMenorXError]</pre>
#A través de comando loop, descubrir el primer valor que es más pequeño
que el XError + 1 standard deviation
i=1
while(arbbaja$cptable$xerror[i] > (xerror+sd))
  i = i + 1
#Valor de Complexity Parameter
optimalTreeCP <- arbbaja$cptable$CP[i]</pre>
optimalTreeCP
## [1] 0.007541478
#Considerando el valor de CP que hemos atribuido anteriormente, tenemos
que descubrir las variables mas importantes
p1 <- prune(arbbaja,cp = optimalTreeCP)</pre>
barplot(p1$variable.importance)
```



R.: El arbol optimo que hemos obtenido es de numero 11 de la cptable con complexity parameter de 0.007541478. Las variables que han sido mas importantes en la definición del arbol optimo han sido Total\_vista (que no se ve a través del grafico), dif\_Libreta.

# 5. Represente gráficamente el árbol óptimo y liste sus reglas de decisión.

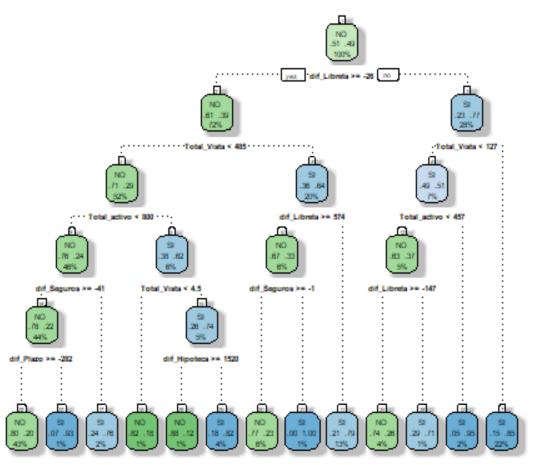
```
#Ambos plots representan graficamente el arbol optimo. En este ejercicio
hemos elegido utilizar el fancyRpartPlot del paquete rattle
#library(rpart.plot)
#rpart.plot(p1)

library(rattle)

## Warning: package 'rattle' was built under R version 3.6.2

## Rattle: A free graphical interface for data science with R.
## Version 5.3.0 Copyright (c) 2006-2018 Togaware Pty Ltd.
## Type 'rattle()' to shake, rattle, and roll your data.

fancyRpartPlot(p1)
```



Rattle 2020-jan-14 22:20:23 Daniel

```
asRules(p1)
##
    Rule number: 21 [Baja=SI cover=12 (1%) prob=1.00]
##
##
      dif_Libreta>=-25.54
##
      Total_Vista>=484.5
##
      dif_Libreta>=574.2
##
      dif_Seguros< -1
##
##
    Rule number: 13 [Baja=SI cover=21 (2%) prob=0.95]
      dif_Libreta< -25.54</pre>
##
##
      Total_Vista< 126.5
##
      Total_activo>=457
##
    Rule number: 33 [Baja=SI cover=14 (1%) prob=0.93]
##
##
      dif_Libreta>=-25.54
##
      Total_Vista< 484.5
##
      Total_activo< 800
##
      dif_Seguros>=-40.64
```

```
##
      dif_Plazo< -282.5
##
##
    Rule number: 7 [Baja=SI cover=292 (22%) prob=0.85]
##
      dif_Libreta< -25.54
##
      Total_Vista>=126.5
##
##
    Rule number: 39 [Baja=SI cover=60 (4%) prob=0.82]
##
      dif_Libreta>=-25.54
##
      Total_Vista< 484.5
##
      Total activo>=800
##
      Total_Vista>=4.5
##
      dif_Hipoteca< 1520
##
##
    Rule number: 11 [Baja=SI cover=178 (13%) prob=0.79]
      dif Libreta>=-25.54
##
##
      Total Vista>=484.5
##
      dif_Libreta< 574.2
##
    Rule number: 17 [Baja=SI cover=25 (2%) prob=0.76]
##
##
      dif Libreta>=-25.54
##
      Total_Vista< 484.5
##
      Total_activo< 800
##
      dif_Seguros< -40.64
##
##
    Rule number: 25 [Baja=SI cover=17 (1%) prob=0.71]
##
      dif_Libreta< -25.54
##
      Total_Vista< 126.5
##
      Total_activo< 457
##
      dif_Libreta< -146.9
##
##
    Rule number: 24 [Baja=NO cover=50 (4%) prob=0.26]
##
      dif Libreta< -25.54
##
      Total_Vista< 126.5
##
      Total activo< 457
##
      dif_Libreta>=-146.9
##
##
    Rule number: 20 [Baja=NO cover=75 (6%) prob=0.23]
##
      dif Libreta>=-25.54
##
      Total Vista>=484.5
##
      dif Libreta>=574.2
##
      dif_Seguros>=-1
##
##
    Rule number: 32 [Baja=NO cover=571 (43%) prob=0.20]
##
      dif_Libreta>=-25.54
##
      Total_Vista< 484.5
##
      Total_activo< 800
##
      dif_Seguros>=-40.64
##
      dif Plazo>=-282.5
##
## Rule number: 18 [Baja=NO cover=17 (1%) prob=0.18]
```

```
##
      dif_Libreta>=-25.54
##
      Total Vista< 484.5
      Total activo>=800
##
      Total Vista< 4.5
##
##
    Rule number: 38 [Baja=NO cover=8 (1%) prob=0.12]
##
      dif Libreta>=-25.54
##
      Total Vista< 484.5
##
      Total activo>=800
##
      Total Vista>=4.5
      dif Hipoteca>=1520
```

6. Las probabilidades de baja no están por fortuna equidistribuidas, sino que la probabilidad de baja es muy inferior (un 5%). Exporte a Excel la tabla de resultados por hoja y pondere estos resultados de acuerdo con las probabilidades a priori mencionadas. Obsérvese que en este caso no utilizamos una muestra test de validación del árbol obtenido (en general deberíamos obtener la predicción del árbol en una muestra independiente (test) y validar la calidad del árbol con los resultados obtenidos en esta muestra test).

```
leaf <- subset(p1$frame, var=="<leaf>",select=c(n,yval2))
numLeaf <- row.names(leaf)</pre>
leaf <- data.frame(leaf$n, leaf$yval2)</pre>
names(leaf) <-</pre>
c("n train","class train","n1 train","n2 train","p1 train","p2 train","pr
obnode_train")
row.names(leaf) <- numLeaf</pre>
leaf <- leaf[order(-leaf$p2_train),]</pre>
leaf$cum n1 <- cumsum(leaf$n1 train)/sum(leaf$n1 train)</pre>
leaf$cum n2 <- cumsum(leaf$n2 train)/sum(leaf$n2 train)</pre>
leaf$dif_cum <- leaf$cum_n2 - leaf$cum_n1</pre>
print(leaf)
      n train class train n1 train n2 train
                                                 p1 train p2 train
##
## 21
           12
                         2
                                            12 0.00000000 1.0000000
                         2
## 13
           21
                                   1
                                            20 0.04761905 0.9523810
                         2
## 33
           14
                                   1
                                           13 0.07142857 0.9285714
## 7
          292
                          2
                                  44
                                           248 0.15068493 0.8493151
                         2
## 39
           60
                                  11
                                            49 0.18333333 0.8166667
## 11
          178
                         2
                                  38
                                           140 0.21348315 0.7865169
           25
                          2
                                            19 0.24000000 0.7600000
## 17
                                   6
                                   5
## 25
           17
                         2
                                            12 0.29411765 0.7058824
                                  37
## 24
           50
                                            13 0.74000000 0.2600000
```

```
## 20
           75
                                58
                                         17 0.77333333 0.2266667
          571
                        1
## 32
                               455
                                        116 0.79684764 0.2031524
## 18
           17
                        1
                                14
                                          3 0.82352941 0.1764706
## 38
            8
                        1
                                 7
                                          1 0.87500000 0.1250000
##
      probnode train
                          cum n1
                                     cum n2
                                                 dif cum
## 21
         0.008955224 0.000000000 0.01809955 0.018099548
## 13
         0.015671642 0.001477105 0.04826546 0.046788355
## 33
         0.010447761 0.002954210 0.06787330 0.064919093
         0.217910448 0.067946824 0.44193062 0.373983794
## 7
## 39
         0.044776119 0.084194978 0.51583710 0.431642126
## 11
         0.132835821 0.140324963 0.72699849 0.586673529
## 17
         0.018656716 0.149187592 0.75565611 0.606468516
## 25
         0.012686567 0.156573117 0.77375566 0.617182539
## 24
         0.037313433 0.211225997 0.79336350 0.582137502
         0.055970149 0.296898080 0.81900452 0.522106445
## 20
## 32
         0.426119403 0.968980798 0.99396682 0.024986020
         0.012686567 0.989660266 0.99849170 0.008831438
## 18
## 38
         0.005970149 1.000000000 1.00000000 0.000000000
tab results = data.frame(matrix(NA, nrow=nrow(leaf), ncol=4))
row.names(tab results) = row.names(leaf)
tab results[,1] = leaf$n train + leaf$n train
tab_results[,2] = leaf$n1_train + leaf$n1_train
tab_results[,3] = leaf$n2_train + leaf$n2_train
tab_results[,4] = tab_results[,3]/tab_results[,1]
names(tab_results) = c("n","n1","n2","p2")
tab_results = tab_results[order(-tab_results$p2),]
#print(leaf)
Sys.setenv(JAVA_HOME='C:\\Program Files\\Java\\jdk1.8.0_231\\jre')
library(xlsx)
write.xlsx(tab_results, "tab_results.xlsx")
```

# 7. Obtenga gráficamente las curvas de concentración y ROC correspondientes.

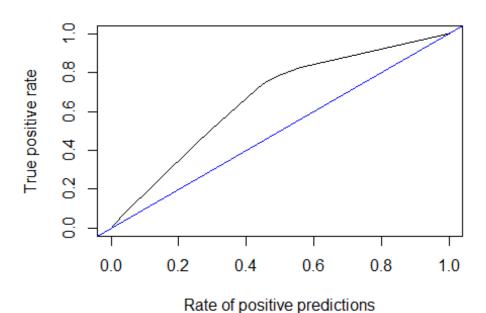
```
pred_learn <- as.data.frame(predict(p1,
    data=churn_tidy[trainingdata,],type="prob"))
pred_test <- as.data.frame(predict(p1, newdata=churn_tidy[-
    trainingdata,],type="prob"))

library(ROCR)
## Warning: package 'ROCR' was built under R version 3.6.2
## Loading required package: gplots
##
## Attaching package: 'gplots'</pre>
```

```
## The following object is masked from 'package:stats':
##
## lowess

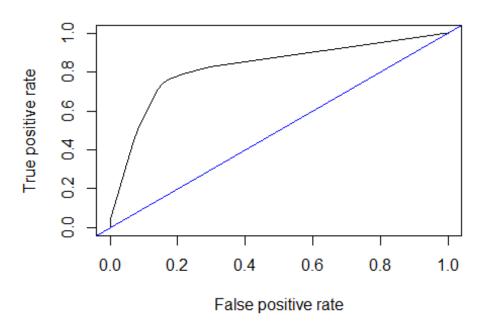
pred <- prediction(c(pred_learn$SI,pred_test$SI),
c(churn_tidy$Baja[trainingdata],churn_tidy$Baja[-trainingdata]))
con <- performance(pred,measure="tpr",x.measure="rpp")
plot(con, main="Concentration curve")
abline(0,1,col="blue")</pre>
```

## **Concentration curve**



roc <- performance(pred, measure="tpr", x.measure="fpr")
plot(roc, main="ROC curve")
abline(0,1,col="blue")</pre>

#### ROC curve



```
auc.tmp <- performance(pred,"auc")
auc <- as.numeric(auc.tmp@y.values)

#Valor del area entre la curva ROC y la linea diagonal
auc
## [1] 0.823641</pre>
```

8. Decida un umbral de decisión para la predicción de "baja" y obtenga el "error\_rate", la precisión en la predicción positiva, la precisión en la predicción negativa, el promedio de ambas precisiones y el Recall asociado al umbral escogido.

Resp.: Los resultados pueden ser vistos en el archivo adjunto "Exercise-CART-08-01-2020.xlsx"